

Soixante-dix ans, une douzaine de noms.

Le même projet — faire faire à une machine ce qui demande de l'intelligence — a changé d'étiquette à chaque fois que la précédente s'est dévaluée.

45

minutes, une seule fois,
avant le module 00

Aucun livrable. Un socle commun.



en orange, les deux hivers de l'IA

Quand un mot nouveau apparaît, demandez ce qu'il fait que le précédent ne faisait pas. Souvent, rien.

Le chemin de vos données.

« Est-ce que mes données servent à entraîner le modèle ? » n'a pas de réponse unique : elle dépend de l'étape.

Une fois

Préparation, hors ligne

- 01 Vos sources
- 02 Extraction
- 03 Découpage
- 04 Vectorisation
- 05 Index

Vos documents sont copiés et stockés chez quelqu'un.

À chaque demande

Quelques secondes

- 06 Votre demande
- 07 Recherche
- 08 Contexte assemblé
- 09 Tokens
- 10 Génération

L'étape 08 est le point de sortie réel.

Autour

Ce qui encadre

- 11 Outils & actions
- 12 Vérification humaine
- 13 Journal & coûts

Sans journal, impossible d'expliquer une réponse aberrante ni d'estimer un coût.


Vos données sortent à l'étape 08 — et la fuite la plus fréquente vient de l'étape 06 : ce qu'on colle sans y penser.

Ce qu'il y a dans la boîte.

Ce n'est pas un cerveau. Un neurone additionne ce qui lui arrive, chaque signal multiplié par son poids.

Entrées, couches, sortie


Chaque trait porte un poids : c'est ce qui est appris.




Un modèle, ce sont ces poids : des centaines de milliards de nombres, figés à la fin de l'entraînement.

Ce qui sort : une distribution, pas une réponse

« La capitale de la France est... »



« Le chiffre d'affaires 2025 de votre société est de... »



Il n'existe pas de case « je ne sais pas ».

En séance : basculer d'un exemple à l'autre, puis demander au groupe où le modèle pourrait dire « je ne sais pas ».

Sur quoi ça tourne.

Les poids ne flottent pas dans le vide. Huit couches, de la terre jusqu'à votre écran.

		ON SE MESURE EN
LOGICIEL	08 Votre application	des clics
	07 L'API	des requêtes par minute
	06 Le service d'inférence	des jetons par seconde
	05 L'orchestration	des machines
MATÉRIEL	04 Le réseau interne	des gigaoctets par seconde
	03 Le calcul	des processeurs graphiques
PHYSIQUE	02 Le refroidissement	des litres d'eau
	01 Le site et l'électricité	des mégawatts

On n'installe pas un centre de données où l'on veut : on l'installe où il y a du courant disponible.

Ce que ça coûte à la planète.

Deux échelles à ne jamais confondre : ce que coûte votre requête, et ce que coûte l'ensemble.

0,24

Wh par requête texte

43 secondes de cerveau humain.
Il en faudrait 2 000 pour égaler
une journée de réflexion.

0,34

Wh, autre estimation

Une minute de cerveau.
Recharger un téléphone
consomme quarante fois plus.

72 816

tonnes de CO₂e

L'entraînement d'un seul
modèle : autant que 8 900
Français pendant un an.

945

TWh en 2030

Plus de deux fois la
consommation électrique de la
France, qui était de 451 TWh
en 2025.

Le levier n'est pas d'utiliser moins l'IA, c'est de ne pas envoyer trente pages à chaque question.